

딥러닝 실습 프로젝트 보고서

폐음 분석을 통한

호흡기 질환 자가진단



과목명	딥러닝실습
이름	한자영
학번	24011559

목차

0. 개요

1. 서론

2. 데이터 전처리 및 도메인 적응

3. 호흡 신호 구간화 및 데이터 구조화 전략

4. EfficientNet 기반 학습 실험 및 결과 분석

5. 'WhatBreath' 서비스 구현

6. 한계 및 향후 개선 방향

7. 참고 문헌 및 데이터 출처

0. 개요

본 프로젝트는 스마트폰 마이크를 활용하여 가정 내에서 간편하게 호흡기 건강을 점검할 수 있는 기초 폐음 자가진단 웹 서비스 'WhatBreath'의 개발 과정을 다룬다. 임상 환경에서 정밀 측정된 청진기 데이터와 실제 스마트폰 녹음 환경 간의 도메인 불일치(Domain Mismatch) 문제를 해결하기 위해, MEMS 마이크 주파수 응답 특성을 반영한 곡선형 EQ 필터 및 ESC-50 기반의 주변 생활 소음(SNR 15dB) 증강 기법을 제안한다. 또한, 의료 스크리닝 목적에 부합하도록 라벨 스무딩(0.05) 및 드롭아웃(0.4)을 튜닝하여 정상/비정상 클래스 간 precision-recall이 모두 0.73으로 균형을 이루며, 전체 정확도(Accuracy) 73.3%를 달성함으로써, 선행연구(Petmezas et al., 2022) 대비 우수한 ICBHI Score(0.7325)를 확보하여 이진 분류(Binary Classification) 파이프라인을 구축하였다.

1. 서론

1.1 연구 배경 및 필요성

현대 의학에서 폐음 청진은 호흡기 질환(천식, 만성폐쇄성폐질환, 폐렴 등)을 진단하는 가장 기초적이고 중요한 스크리닝 수단이다. 그러나 기존의 정밀 청진 시스템은 병원 방문이 필수적이며 고가의 장비가 요구된다는 한계가 있다. 만성 호흡기 질환자나 영유아 가정을 위해서는 일상 공간에서 주기적으로 호흡 상태를 모니터링할 수 있는 저비용·고효율의 자가진단 시스템이 요구된다. 최근 딥러닝 기반의 오디오 인식 기술이 발전함에 따라, 보편적인 디바이스인 스마트폰을 활용한 폐음 분석 시스템의 가능성이 대두되고 있다.

1.2 기존 연구의 한계점: 도메인 불일치 (Domain Mismatch)

AI 기반 폐음 진단 모델을 학습시키기 위해 공개된 데이터셋(ICBHI 등)은 대다수 소음이 통제된 임상 환경에서 전문 의료용 청진기(Stethoscope)로 녹음된 데이터이다. 이를 그대로 스마트폰 녹음 환경에 적용할 경우 다음과 같은 치명적인 한계가 발생한다.

-하드웨어적 한계: 스마트폰 내장 MEMS 마이크는 인간의 음성 대역에 최적화되어 있어, 저음역대의 미세한 폐음 신호 감쇄 및 특정 고음역대의 공명 현상을 유발한다.

-환경적 한계: 가정 내 녹음 시 가전제품 소음, 가전제품 작동 소리, 도로 소음 등 다양한 주변 생활 소음(Background Noise)이 혼입되어 AI 모델의 오작동을 유발한다.

실제로 스마트폰과 디지털 청진기 간 호흡음 녹음을 비교한 임상 연구에서도, 두 기기 간 이상음 검출 일치도가 제한적임이 보고된 바 있다(Baptista et al., 2026).

1.3 제안 방법 및 핵심 기여

본 연구에서는 이러한 도메인 불일치 문제를 극복하고 실전 웹 서비스에서 안정적으로 작동하는

파이프라인을 구축하기 위해 다음과 같은 접근법을 제시한다.

1. **물리 기반 도메인 적응 (Domain Adaptation):** CycleGAN 기반 비지도 변환을 시도했으나 학습 불안정성 및 성능 저하가 확인되어 스마트폰 마이크의 주파수 응답 특성을 모사한 '곡선형 EQ 필터'를 설계하여 청진기 데이터를 스마트폰 도메인으로 변환한다.
2. **소음 정합 정규화 (Noise Regularization):** 노이즈 증강은 두 가지 방법으로 구성된다. 가우시안 노이즈를 SNR 15dB로 고정하여 합성하고, ESC-50 환경 소음 데이터셋을 활용하여 현실적인 생활 소음(SNR 15~20dB)을 전체 데이터의 50% 비율로 합성함으로써 모델의 강인함을 확보한다.
3. **의료 목적형 하이퍼파라미터 최적화:** 수집 데이터의 호흡 사이클 길이 분포를 고려해 5초 슬라이딩 전략을 도입하고, 라벨 스무딩과 드롭아웃을 통해 과적합을 완화하며 정상, 비정상 클래스 간 precision-recall이 균형을 이루는 모델을 제작한다.

2. 데이터 전처리 및 도메인 적응

2.1 오디오 데이터 수집 및 물리적 특성 분석

본 연구에서는 가정 내 스마트폰 환경에서 신뢰성 있는 호흡기 질환 자가진단 서비스를 구현하기 위해, 임상 폐음 데이터셋인 ICBHI(International Conference on Biomedical and Health Informatics) 2017 데이터셋을 기초 연구 자료로 수집 및 분석하였다. ICBHI 2017 데이터셋은 총 126명의 환자로부터 수집된 920개의 녹음 파일과 6898개의 호흡 주기로 구성되어 있다. 해당 데이터는 정상(Normal), 수포음(Crackle), 천명음(Wheezing), 그리고 수포음과 천명음이 동시에 발생하는 복합음(Both)으로 라벨링되어 있어 딥러닝 기반 알고리즘의 훈련 기반을 제공한다. 그러나 이를 스마트폰 환경에 직접 적용하기에는 청진기와 스마트폰 사이의 하드웨어의 물리적 스펙트럼에서 차이가 존재한다. 호흡기 질환에 의한 폐음은 일반적으로 25~1500Hz 대역에 분포한다(TTAC). 의료용 청진기는 저주파 대역의 소리를 미세하게 잡아내도록 설계되어 있으나, 스마트폰 마이크는 고주파 대역의 음성 신호 검출 효율을 극대화하고 주변 소음을 억제하기 위해 저주파를 강제로 감쇄하고 특정 음성 대역에 가중치를 부여하는 특성을 보인다. 결과적으로 의료용 데이터셋(ICBHI 2017)으로만 100% 학습된 딥러닝 분류 모델은 고해상도의 주파수 환경에만 과적합(Overfitting)된다. 이러한 모델을 실제 서비스 환경에 적용할 경우 스마트폰 마이크 고유의 저주파 감쇄 특성으로 인해 Mel-Spectrogram에서 폐음 특유의 불연속적 주파수가 흐려지거나 소실되며 가정 내에서 발생하는 일상 소음과 스마트폰 기기 자체의 열잡음이 폐음 신호에 중첩되어 신호 대 잡음비(SNR)이 급격히 저하된다. 음향학적 데이터 격차는 도메인 불일치를 야기하며, 이는 베이스라인 모델의 실제 테스트 정확도를 떨어뜨리는 주 원인이 된다. 따라서 본 프로젝트에서는 임상 폐음 데이터를 스마트폰 환경에 맞게 강제로 왜곡 및 오염시키는 '스마트폰 도메인 적응 알고리즘'을 전처리 단계에서 수행하게 되는 핵심적 원인이 된다.

2.2 CycleGAN 기반 도메인 변환의 한계

초기 단계에서 전문 의료용 청진기 도메인의 폐음 데이터를 스마트폰 수집 환경의 도메인으로 변환하기 위해 비지도 학습 기반의 CycleGAN 모델을 도입하였다. 1차적으로 오디오 데이터를 5초 단위로 슬라이싱하여 50epoch 동안 학습시켰으나, 오디오 파일에 대한 폐음 라벨(수포음, 천명음)이 5초 단위의 시간 구간과 대응되지 않는 구조적 한계가 존재했다. 이에 따라 호흡 주기 및 라벨 간격을 고려하여 데이터를 3초 단위로 새롭게 설정한 후 라벨을 정렬하였다. 그러나 입력 크기 불일치로 인해 학습 중 모델 붕괴(model collapse)가 발생해 변환 결과에 세로줄 형태의 인공물이 생겼다. LAMBDA_CYC와 LAMBDA_ID 값을 높여 원본 특징 보존을 강화했지만, 학습을 거치지 않은 동일 데이터로 EfficientNet을 학습했을 때 원본 청진기 데이터보다 낮은 성능을 보였다. 이는 CycleGAN을 활용한 도메인 변환이 분류에 필수적인 특징을 손상시키는 것으로 해석할 수 있다. 성능 저하의 근본적인 원인은 변환 대상이 된 스마트폰 도메인 데이터셋의 물리적 성격 차이에서 비롯된다. 학습에 사용된 스마트폰 데이터셋은 호흡음 데이터가 아닌, 일반적인 일상 환경에서의 소음 데이터였기 때문이다. 생성 모델은 폐음 데이터를 보존하지 못하고 일상 소음의 무작위한 주파수를 학습하게 되어 형태학적 비대칭성이 생긴다. 결과적으로 이는 학습이 무너지는 결정적 원인이 되었으며, 폐음 분류에 필수적인 음향학적 특징을 손상시켰다.

2.3 하드웨어 특성을 반영한 곡선형 EQ 필터 설계

2.2에서 언급한 CycleGAN 기반 스타일 변환의 정보 손실 및 한계를 극복하기 위해, 하드웨어의 물리적 음향 특성을 제어할 수 있는 결정론적 신호 처리 기반의 곡선형 이퀄라이저(EQ) 필터 파이프라인으로 전환하였다. 스마트폰 마이크의 고유 특성인 저주파 감쇄 현상을 모사하고 의료용 청진기 도메인과 격차를 보정하기 위해 scipy 라이브러리의 PchipInterpolator를 도입하였다. 선형 보간이나 큐빅 스플라인은 주파수 경계면에서 오버슈트를 유발하여 미세한 호흡음 파형을 왜곡할 위험이 있다. 반면, Pchip 보간법은 단조성을 보존하여 주파수 응답 곡선을 매끄럽게 연결한다는 강점이 존재한다. EQ 필터의 저주파 감쇠(0~100Hz 구간) 및 고주파 증폭(4kHz 이상) 설계는 MEMS 마이크의 일반적인 주파수 응답 특성에 근거한다. MEMS 마이크는 헬름홀츠 공명(Helmholtz resonance) 효과로 인해 100Hz 이하에서 감도가 저하되고 4~6kHz부터 감도가 상승하는 경향을 보이며(Widder & Morcelli, 2014), 이로 인해 다수의 MEMS 마이크 사양서는 주파수 응답을 100Hz~10kHz 구간으로만 명시한다. 한편 폐음의 일반적으로 인정되는 주파수 범위는 약 25~1500Hz이며, 청진기의 다이어프램(diaphragm) 모드는 20~2000Hz 대역을 커버한다(TTAC, n.d.). 본 프로젝트의 EQ 설계에서 150~1500Hz 구간을 0dB로 유지(보존)한 것은 이 폐음 핵심 주파수 대역을 훼손하지 않기 위함이다.

2.4 주변 환경 소음(ESC-50) 및 가우시안 노이즈 합성

가우시안 노이즈 합성을 통해 하드웨어의 열잡음의 특성을 모사한 후 실제 사용자가 'WhatBreath' 서비스를 이용하는 가정 및 일상 공간의 환경적 특징을 정밀하게 투영하기 위해 환경 소음 데이터인 ESC-50을 합성하는 파이프라인을 최종적으로 구축하였다. 스마트폰 내부 회로 및 마이크 센

서 고유의 열잡음을 모사하기 위해 모든 훈련 데이터셋에 신호 대 잡음비(SNR) 고정 수치의 가우시안 노이즈를 일괄 합성하였다. 이는 스마트폰 기기 자체에서 발생하는 노이즈를 물리적으로 고착화하기 위함이다. ESC-50에서는 50개의 클래스 중 실제 가정에서 발생할 수 있는 소음(기침 소리, 발소리, 비 오는 소리 등)을 원본 데이터에 50%의 확률로 합성하였다. 데이터에 인위적으로 노이즈를 주입하는 작업은 분류 모델의 학습 난이도를 높여 초기에는 정확도를 떨어뜨리는 것처럼 보이지만, 이는 모델이 깨끗한 데이터의 사소한 특징을 외우는 과적합을 차단하여 역설적으로 정확도를 높인다. 그 결과, 정확도가 최종적으로 73%에 달하며 실제 사용 환경에 견딜 수 있는 강력한 일반화 성능 및 해석 가능성을 확보하였다.

3. 호흡 신호 구간화 및 데이터 구조화 전략

3.1 수집 데이터 길이 분포 분석 및 5초 슬라이싱(Slicing) 도입 배경

ICBHI 데이터셋 데이터의 호흡에 따라 나눈 결과 총 6898개의 오디오 샘플을 도출할 수 있고, 그 중 3초 이하의 단기 오디오 샘플이 4472개로 전체의 64.8%를 차지하고 있으며, 5초 이하의 데이터는 총 6664개로 전체의 96.6%라는 압도적인 비중을 형성한다. 이처럼 샘플 간의 타임프레임이 극심하게 불균일하므로, EfficientNet-B0 모델의 안정적인 작동을 위해서는 구간별 데이터 길이를 고정하는 것이 필수적이었다. 프로젝트에서 최종적으로 고정 슬라이싱 단위를 '5초'로确定的한 배경은 다음과 같다. 만약 고정 길이를 3초로 잡을 경우 3초를 초과하는 35.2%의 데이터가 학습을 방해할 것이며, 사용할 경우 뒷부분이 잘려 나가는 정보 손실이 일어난다. 또한 사용자의 일반적인 호흡 주기를 고려함에 따라 최종 구간을 5초로 슬라이싱하여 EfficientNet-B0 모델의 입력 데이터셋을 구축하였다. 이후 Train/Val/Test 데이터의 비율을 70/15/15로 나누어 모델 학습에 적용하였다.

3.2 의학적 스크리닝을 위한 다중 클래스 통합 및 이진 분류 전환

ICBHI 데이터셋은 평균 2.7초 단위의 호흡 사이클로 정상, 수포음, 천명음 여부가 표시된다. 그러나 3.1에서 도입한 5초 슬라이싱 분할 알고리즘을 적용할 경우, 하나의 구간 내에서 서로 다른 라벨을 가진 다수의 호흡 사이클이 겹치는 현상이 발생하는데, 이때 폐음을 잡는 것에 중점을 두기 위한 방법을 수립하였다. 분할된 5초 구간 내에 포함된 여러 사이클 중, 겹침 시간이 더 긴 라벨을 채택하는 라벨링 규칙을 정의하였다. 이는 호흡 사이클 경계가 5초 단위 구간과 정확히 일치하지 않는 데이터의 구조적 특성을 반영한 결정으로, 각 구간 내에서 실제로 더 많은 시간을 차지하는 음향 패턴을 그 구간의 대표 라벨로 채택함으로써 라벨링의 일관성을 확보하였다.

3.3 라벨 스무딩(Label Smoothing)을 통한 데이터 불확실성 극복

3.2에서 수립한 규칙은 라벨링의 일관성을 확보하는 데는 부합하나, 딥러닝 모델의 학습 관점에서는 일종의 노이즈와 불확실성을 내포하게 된다. 5초 구간 중 폐음이 없지만 1로 분류되는 경우의

존재 가능성이 있기 때문에 손실 함수가 정답 확률을 무조건 100%로 맞추도록 강제한다면 과적합이 발생하거나, 잘못된 학습을 하게 될 가능성이 높아진다. 따라서 스마트폰 수집 환경 특유의 음향적 잡음과 보수적 라벨링 전략이 야기하는 데이터 불확실성을 수학적으로 통제하기 위해 라벨 스무딩 기법을 도입하였다. 라벨 스무딩은 기존의 극단적인 타겟 확률 분포 $[0, 1]$ 을 일정한 평활화 계수($\alpha=0.05$)를 기반으로 부드럽게 깎아주어 소프트 라벨(Soft Label)인 $[0.05, 0.95]$ 형태로 변환하는 정규화 기술이다. 라벨 스무딩을 적용한 결과, EfficientNet-B0 분류기는 노이즈의 특정 픽셀이나 미세 주파수에 크게 영향을 받지 않고, 경계면의 불확실성을 인정하고 호흡음의 전반적인 맥락적 특징을 학습함으로써, 학습 과정에서의 손실 값 수렴 안정성이 크게 향상되었다. 결과적으로 이는 모델이 미세한 소음이나 기기별 하드웨어 편차에 흔들리지 않게 만드는 방어벽 역할을 하였으며, 드롭아웃(0.4), LR($2e-4$) 등과 함께 적용되어, 최종적으로 73.3%의 정확도를 보이는 모델로 이어졌다.

4. EfficientNet 기반 학습 실험 및 결과 분석

4.1 딥러닝 기반 폐음 분류 모델 구조 (EfficientNet-B0)

본 연구에서 제안하는 스마트폰 기반 호흡기 건강 스크리닝 서비스 'WhatBreath'는 병원 내부의 고성능 컴퓨팅 서버가 아닌, 일상적인 웹 환경 및 제한된 자원을 가진 클라이언트 환경에서의 원활한 결과 제공을 목표로 한다. 따라서 분류 모델은 예측 성능을 확보함과 동시에, 연산 파라미터 수가 비교적 적어 실시간 추론에 유리한 경량 구조를 갖추는 것이 바람직하다고 판단했다. EfficientNet은 모델의 깊이, 너비, 입력 해상도를 개별적으로 조절하는 대신 일정한 비율로 동시에 확장하는 복합 스케일링 기법을 제안한 아키텍처로, 동일하거나 더 적은 파라미터 수로 기존 CNN 대비 높은 효율을 달성한 것으로 보고된 바 있다(Tan & Le, 2019). 본 프로젝트에서는 이러한 구조적 특성과 더불어, EfficientNet-B0가 의료·생명과학 분야의 이미지 분류 과제에서도 실제로 우수한 성능을 보인 선행 연구를 참고하여 분류 모델로 채택했다. 구체적으로 Shim 등(2024)은 5등급 배아 품질 분류 과제에서 EfficientNet-B0를 InceptionV3, ResNet18, ResNet50, VGG16과 비교한 결과, EfficientNet-B0가 정확도·ROC-AUC-F1-score 전 지표에서 가장 우수한 성능을 보였음을 보고했다. 이는 EfficientNet-B0가 전형적인 자연 이미지가 아닌, 세밀한 패턴 구분이 요구되는 의료·생체 이미지 분류 과제에서 효과적으로 작동할 수 있음을 시사한다. 이러한 선행 연구 결과를 근거로, 본 프로젝트는 EfficientNet-B0를 Mel-Spectrogram 기반 호흡음 분류에 적용했다.

4.2 하이퍼파라미터 조정

하이퍼파라미터는 체계적인 자동 탐색 대신, 검증 성능을 기준으로 한 반복적인 학습 결과를 바탕으로 결정했다. Learning Rate는 $1e-4$, $5e-5$, $3e-4$, $2e-4$ 등 다양한 값으로 시도를 한 결과 $2e-4$ 에서 가장 안정적인 수렴을 보였으며 Dropout rate는 0.3에서 0.4로 조정하여 과적합을 방지하였을 때 검증 성능이 개선되었다.

4.3 실험 결과 및 성능 평가지표 분석

본 프로젝트에서는 ICBHI Score, Confusion Matrix, 클래스별 F1-score, ROC 커브를 활용하여 모델의 성능을 평가하였다. ICBHI 공식 챌린지에서는 Train/Test를 60:40 split 기준으로 계산해야 기존 연구와 비교가 가능하다는 의미가 성립하는데, 본 연구에서는 70:15:15로 직접 나눈 split을 사용하였다. 따라서 ICBHI Score의 산식을 차용했지만 공식 split 기준이 아닌 자체적인 split을 기준으로 평가 지표에 적용하였다. Confusion Matrix의 결과는 [[215 79] [78 215]]로 Sensitivity와 Specificity는 모두 약 0.73이다. 이에 따라 $(\text{Sensitivity} + \text{Specificity}) / 2$ 로 계산하는 ICBHI Score 역시 0.73로 출력된다. 공식적인 ICBHI Score split 기준을 사용한 Petmezas et al.(2022)의 CNN-LSTM 모델의 64.92%와 비교하였을 때 split 기준이 다름에도 73%는 제법 높은 수치임을 알 수 있다. 아울러, 모델의 클래스 변별력을 나타내는 ROC AUC 지표는 0.8028을 기록하였다. 가우시안 노이즈와 ESC-50이 복합 주입되어 도메인이 변한 데이터를 측정된 모델이 0.8 이상의 AUC를 기록했다는 점은 가정 내 스마트폰 청취 환경에서도 모델이 정상과 이상 징후를 일정 수준 구별해낼 수 있는 변별력을 갖추었음을 시사한다.

5. 'WhatBreath' 서비스 구현

5.1 'WhatBreath'의 전체적 서비스 구현

App.py는 best_model.pth를 불러와 두 개의 엔드포인트를 제공한다. /analyze-segment는 단일 5초 구간을 받아 정상/비정상 확률을 반환하고, /analyze-full은 15초 전체 녹음을 받아 3구간으로 분할한 뒤 다수결로 종합 판정하고 Groq API로 조언 문구까지 생성해 반환한다. 학습 시에는 청진기 데이터에 EQ 필터와 노이즈를 합성해 스마트폰 도메인처럼 변환했지만, 추론 시 사용자의 입력은 이미 실제 스마트폰 녹음이므로 EQ나 노이즈 처리 없이 Mel-Spectrogram 변환만 동일하게 적용한다. 프론트엔드는 MediaRecorder API로 브라우저에서 직접 마이크 녹음을 구현했으며, 15초 동안 5초 단위로 진행 상황을 표시한다. 녹음 또는 업로드된 오디오가 최소 길이(15초) 미만이면 분석을 차단하고 재녹음을 안내한다. 결과 화면에는 구간별 정상/이상 카드, 해당 구간의 Mel-Spectrogram, 종합 판정, AI 조언을 표시하며, 정상(녹색)·비정상(빨강)·주의(옐로)·노이즈(주황) 네 가지 상태를 시각적으로 구분했다. Groq 연동을 통한 조언 생성에서는 API를 통해 분석 결과(구간별 확률, 종합 판정)를 프롬프트에 포함시키고 다음과 같은 안전장치를 적용했다. 의학적 진단이 아닌 참고용 스크리닝임을 명확히 제시하고, 천식이나 폐렴 같은 특정 질병명을 단정적으로 언급하지 않도록 지시했다. 비정상으로 판정된 경우 호흡기내과 진료를 권유하는 기준을 규칙으로 고정했고, 정상/비정상/주의/노이즈 상태별로 별도의 프롬프트 템플릿을 적용해 일관된 톤을 유지했다.

5.2 Flask 기반의 'WhatBreath' 15초 자가진단 웹 서비스 아키텍처

기존의 계획에서는 30초간 폐음을 녹음한 후, 5초 길이의 구간 6개로 나누어 한 구간에서라도 폐

음이 측정되면 비정상으로 분류하고자 하였다. 그러나 최종 모델의 정상 클래스 recall이 0.73 수준임을 고려하면, 진짜 정상인 사용자가 6구간 중 적어도 한 구간에서 오판될 확률은 $1 - 0.73^6 \approx 84.8\%$ 에 달해, 모델 정확도에 비해 거짓양성이 비현실적으로 증폭되는 문제가 있었다. 이를 보완하기 위해 구간별 확률의 중앙값을 기준으로 종합 판정하는 방식을 시도했으나, 실제 테스트 결과 5구간 중 1구간에서만 이상 신호가 감지된 경우에도 중앙값 기반 판정이 이를 거의 무시하는 한계가 확인됐다. 최종적으로 녹음 시간을 15초로 줄여 5초씩 3구간으로 재구성하고, "3구간 중 2구간 이상에서 비정상이 감지될 때만 전체를 비정상으로 판정"하는 다수결(majority vote) 규칙을 채택했다. 이 경우 거짓양성 확률은 $1 - [0.73^3 + 3 \times 0.73^2 \times 0.27] \approx 18.0\%$ 로, OR 규칙 대비 크게 완화된다는. 다만 1구간에서만 이상이 감지되는 경우를 완전히 무시하지 않도록, 종합 판정은 "정상"으로 유지하되 별도의 주의 메시지를 함께 제공하도록 설계했다.

6. 한계 및 향후 개선 방향

학습 데이터의 노이즈 도메인이 단일 화자, 단일 환경의 스마트폰 녹음(2시간 분량) 한 개 파일을 기반으로 했다는 점에서 제한적이다. 다양한 기종과 환경의 스마트폰 폐음 녹음 데이터를 추가로 확보할 수 있다면 일반화 성능 향상을 기대할 수 있다. 또한 EQ 필터의 보정값(dB 커브)은 특정 논문의 수치를 직접 인용한 것이 아닌, 스마트폰과 청진기 사이에서 큰 차이가 나는 부분을 참고하여 임의로 설정한 값이다. 비정상 클래스의 recall이 0.73이므로, 짧게 나타나는 이상음을 놓칠 가능성이 있으므로, 임계값 조정이나 추가 데이터를 통한 개선이 필요하다. 기존에는 4클래스 분류(정상/수포음/천명음/복합음)를 시도했으나 데이터 부족으로 정확도는 36%에 그쳐 채택하지 못했으며, 추가 데이터 확보를 통한 세부 분류 고도화가 필요하다.

7. 참고 문헌 및 데이터 출처

ICBHI 2017 Respiratory Sound Database.

Piczak, K. J. (2015). ESC: Dataset for Environmental Sound Classification.

Baptista, B., Pais-Cunha, I., Amaral, R., Vieira-Marques, P., Valente, J., Almeida, R., Costa-Santos, C., Azevedo, I., Fonseca, J. A., Ferreira-Magalhães, M., & Jácome, C. (2026). Lung auscultation using smartphone built-in microphone versus digital stethoscope: a comparative early feasibility study. *Minerva Pediatrics*, 78(2), 155-163.

Shim, V. J., Shim, H., & Roh, S. (2024). EfficientNet-B0 outperforms other CNNs in image-based five-class embryo grading: a comparative analysis. *Journal of Animal Reproduction and Biotechnology*, 39(4), 267-277.

Petmezas, G., Cheimariotis, G.-A., Stefanopoulos, L., Rocha, B., Paiva, R. P., Katsaggelos, A. K., & Maglaveras, N. (2022). Automated lung sound classification using a hybrid CNN-LSTM network and focal loss function. *Sensors*, 22(3), 1232.

Widder, J., & Morcelli, A. (2014, May 14). Basic principles of MEMS microphones. *EDN*.

Telehealth Technology Assessment Resource Center (TTAC). (n.d.). Electronic stethoscopes – Technology overview. Alaska Native Tribal Health Consortium.

Rocha, B. M., et al. (2019). An open access database for the evaluation of respiratory sound classification algorithms. *Physiological Measurement*, 40(3), 035001.